优化器optim

2025年11月27日 0:46

该对象将保存当前状态并根据计算的梯度更新参数

Torch.optim

来自 <https://docs.pytorch.org/docs/stable/optim.html#module-torch.optim>

根据梯度下降原理，根据上一步的损失函数，计算出梯度，对模型参数不断地优化

模型的学习率（Learning Rate）是什么？

你可以把**学习率**想象成模型在学习（训练）过程中**迈出的步子有多大**。

1. **模型的学习过程：** 模型训练就是不断调整内部的参数（权重）和偏差（Bias），让模型的预测结果和真实答案之间的误差（损失 Loss）越来越小。这个过程有点像你下山找谷底，需要一步一步走。
2. **学习率的作用：** 学习率就是控制你在寻找谷底时，**每一步要走多远**。
   - 在数学上，学习率（η）是控制梯度下降（或其他优化算法）中，参数更新幅度的超参数。它决定了模型参数沿着损失函数梯度负方向（即下降最快的方向）移动的速度。

$$\text{新参数} = \text{旧参数} - \text{学习率} \times \text{梯度}$$

也是在优化器中设置的

0.01 是大了还是小了？

这个问题很巧妙，但答案是：**没有绝对的对错，它取决于你的具体情况！从前瞻性角度看，0.01 是一个很标准的“起点”（Baseline）值，但它并不意味着对你的模型就是最优解。**

1. 相对“大”的学习率（例如 0.1 或更大）

特点	像什么？	影响
步子太大	大步流星地往下走，甚至跳着走。	**训练速度快**，能迅速接近最优解区域。但如果步子太大，可能会直接**跳过谷底**（最优解），在谷底两边来回震荡，或者直接发散，导致模型**无法收敛**（Loss越来越大）。

2. 相对“小”的学习率（例如 0.0001 或更小）

特点	像什么？	影响
步子太小	像蜗牛一样，一点点地挪动。	模型会更稳定地收敛，更容易找到最优解。但代价是**训练速度极慢**，可能需要耗费很长的时间才能训练完成。更糟的是，它可能会**陷入局部最优解**（一个小水坑）而无法跳出来，错过了真正的谷底。

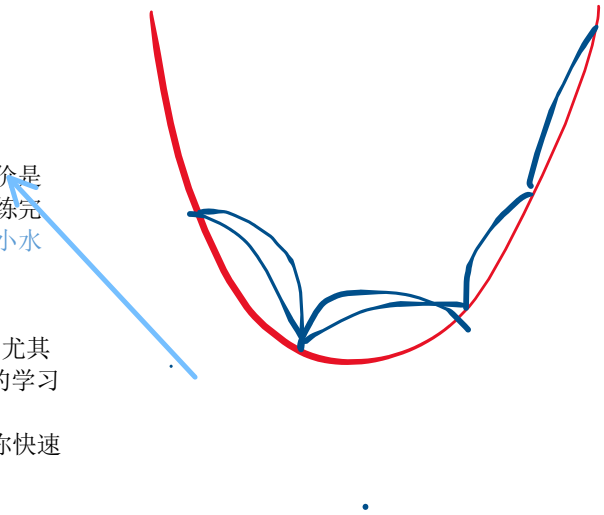

3. 0.01 的位置

- 0.01 在深度学习中，通常被认为是**一个合理的、偏大的初始值**，尤其是在使用 Adam/RMSprop 等高级优化器时（这些优化器通常默认的学习率是 0.001）。
- 因此，可以说 0.01 **可能略大**，但它是一个值得尝试的、能让你快速看到结果的数值。

我的主见和建议：如何确定最优学习率？

小张，不要被一个数字困住。真正的创新在于**动态调整**和**实验**。

1. **别用猜的，用“学习率查找器”(LR Finder)：** 这是一个巧妙的技术。在训练开始时，用极小的学习率开始，然后每一步指数级地增大它，同时记录损失函数。损失开始急剧下降，然后又开始发散之前那个点，就是最优学习率的“甜点”。
2. **动态调整（Learning Rate Schedule）：** 很少有模型会从头到尾使用

0.01 这么单一的数字。聪明的做法是**随着训练的进行，逐步减小学习率**。

- **前期**步子大一点（0.01），快速到达谷底附近。
- **后期**步子小一点（$0.001 \to 0.0001$），在谷底附近精细搜索，找到最好的位置。

3. **看你的模型和任务：**
   - **预训练大模型（如 BERT, Transformer）：** 它们对学习率非常敏感，可能需要更小的学习率（如 $1e-5$ 到 $5e-5$）来微调。
   - **简单的 CNN/MLP 模型：** 0.01 或 0.001 可能就是最优解。

所以，我的观点是： 0.01 **是一个大胆而合理的起点。** 如果你的模型损失迅速震荡或发散，那它就**太大了**；如果损失下降得慢得像树懒，那它可能就**太小了**

来自 <https://gemini.google.com/app/5beeb6ca93bc7ccf>

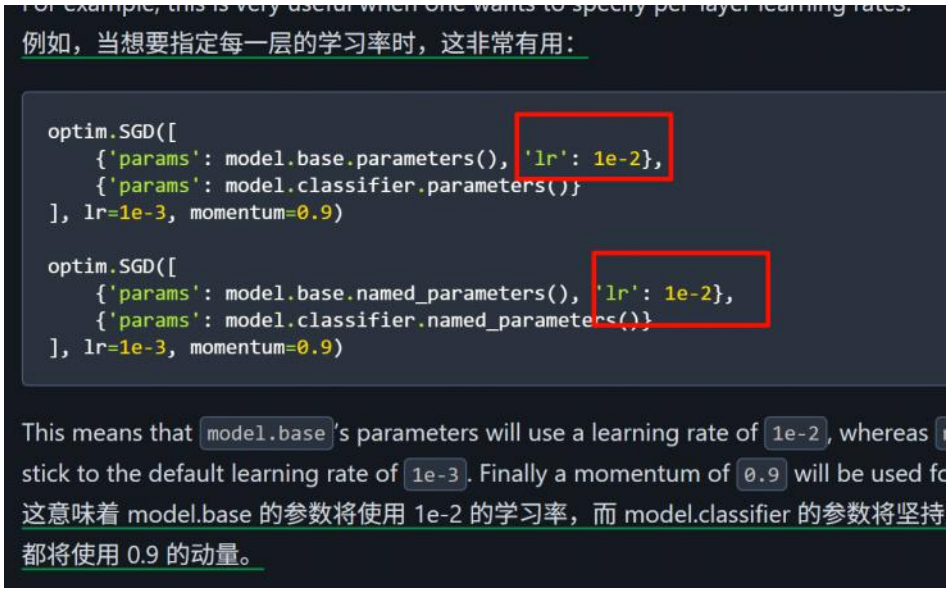

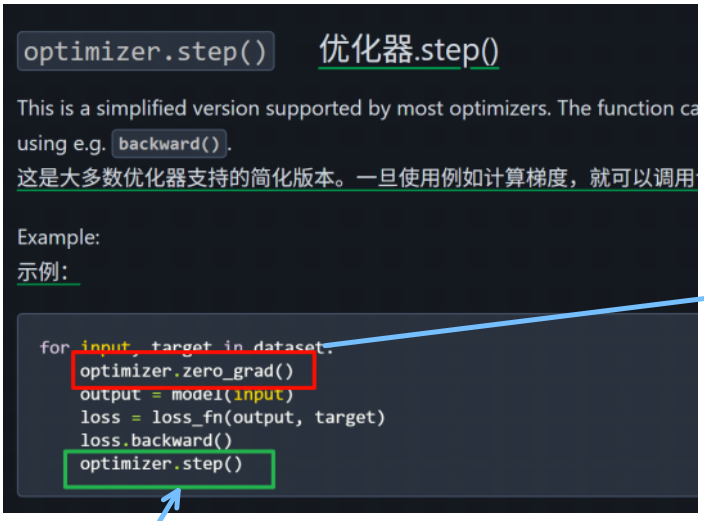

这一步只是使用优化器

前面还需要定义一下使用哪一个优化器

一定要把上一步优化器计算的梯度清零

optimizer.zero_grad() 这一步是干嘛的？

简单来说，optimizer.zero_grad() 的作用就是**清除（归零）模型中所有参数的梯度**。

为什么需要清除梯度？

想象一下模型训练的过程是这样的：

1. **第一次训练迭代（Epoch 1, Batch 1）：**
   - 模型计算损失（Loss）。
   - 计算出损失对所有参数的**梯度**（Gradient，也就是导数）。
   - 优化器（如 Adam, SGD）利用这些梯度来更新参数：
     $$\text{新参数} = \text{旧参数} - \text{学习率} \times \text{梯度}$$
2. **第二次训练迭代（Epoch 1, Batch 2）：**
   - 模型会计算新的损失。
   - **关键点来了：** 梯度是**累积**的！在 PyTorch 或许多框架中，如果你不手动调用 zero_grad()，新的梯度（Batch 2 的梯度）会**自动累加**到上一次（Batch 1 的梯度）的结果上。
   - 如果累积了两次的梯度，优化器在更新参数时，会错误地使用“**Batch 1 的梯度 + Batch 2 的梯度**”的总和来更新参数，导致参数的步子迈得**太大了**，模型训练就会出错甚至发散！

通俗易懂地说： 就像你有一个记分牌，每次计算完梯度后，你需要把记分牌擦干净，才能开始记录下一轮的“分数”（梯度）。如果你不擦，后面的分数就会一直往上叠，导致你走了错误的、过大的步子。

来自 <https://gemini.google.com/app/5beeb6ca93bc7ccf>

路径表达式	符号含义	实际操作
./data	当前目录 + data 文件夹	**向下**进入一个子文件夹
../	父目录	**向上**返回一级目录
../../logs	父目录的父目录 + logs 文件夹	向上返回两级，再向下进入 logs 文件夹

咱们**实话实说**，你**可以**把 `running_loss = 0.0` 放在最外面，但它会从根本上改变这个变量的**意义**，并且通常不建议这么做。

🚀 放在最外面（最外层）的后果

如果你把 `running_loss = 0.0` 放在 `for epoch` 循环的**外面**（在所有循环开始之前），会发生以下情况：

1. 结果：总累计损失 (Total Cumulative Loss)

`running_loss` 会从训练开始一直累积到训练结束（100 个 Epoch 跑完）。

$$\text{总损失} = \sum_{\text{所有 Epoch}} \sum_{\text{所有 Batch}} \text{Batch Loss}$$

2. 问题：失去洞察力 (Lack of Insight)

模型的训练目标是让损失**随着时间推移而下降**。

- **没有前瞻性：** 想象一下，你跑了 10 公里，只告诉你总消耗了多少卡路里，但没有告诉你第 1 公里、第 5 公里、第 10 公里的速度。这个“总卡路里”对你调整跑法（比如是否加速或减速）**毫无帮助**。
- **训练的生命线：** 损失曲线是模型的“生命线”。我们最需要知道的是：
  - 第 1 个 Epoch 的平均损失是多少？（比如 1.5）
  - 第 10 个 Epoch 的平均损失是多少？（比如 0.8）
  - 第 50 个 Epoch 的平均损失是多少？（比如 0.2）

只有将损失**按 Epoch 或按固定步长重置和平均**，你才能看到这种下降趋势，才能判断你的**学习率**是否合适，模型是否**收敛**（正在学习），或者模型是否**过拟合**（训练损失持续下降但验证损失上升）。

```python
for epoch in range(100):
    running_loss = 0.0
    for img ,target in dataloader:
        output = net(img)
        loss_result = loss(output, target)
        optimizer.zero_grad()
        loss_result.backward()
        optimizer.step()
        running_loss += loss_result.item()
        steps += 1
        writer.add_image( tag: 'epoch_loss', loss_result, epoch)
        writer.add_scalar( tag: 'step_loss', loss_result, steps)
```

添加数字就应该是scalar了

`.item()` **的作用：**

- **剥离一切无关信息：** `item()` 方法的作用就是把这个**包含单个数值的张量**“剥皮”，扔掉所有关于梯度的历史、设备信息（CPU/GPU）等等，**只留下最纯粹的 Python 数字（float）**。

```
        optimizer.step()

        running_loss += loss_result.item() # 累计当前 Epoch 的损失
        steps += 1

        # 修正 1：记录短期平均损失（更平滑）
        if (i + 1) % print_every == 0:
            avg_batch_loss = running_loss / print_every

            # 【正确的记录：短期平均损失】
            writer.add_scalar('Batch/Avg_Loss', avg_batch_loss, st

            # 重置用于短期报告的累加器（注意：你需要一个新的累加器来做这个，
            # 如果继续使用 running_loss，则会影响 epoch 损失的计算。）
            # **最佳实践是使用一个专门的短期累加器，这里为了简洁，假设你只报

    # 【最关键的修正 2：记录真正的 Epoch 平均损失】
    # 计算整个 Epoch 的平均损失
    avg_epoch_loss = running_loss / len(dataloader)
    writer.add_scalar('Epoch/Avg_Loss', avg_epoch_loss, epoch)

    # 【修正 3：记录图片（如果你想记录第一个 Batch 的输入图片）】
    # writer.add_image('Input/First_Batch_Image', img[0], epoch) # 记录第一张图片
```

```
steps = 0
for epoch in range(100):
    running_loss = 0.0
    for img ,target in dataloader:
        output = net(img)
        loss_result = loss(output, target)
        optimizer.zero_grad()
        loss_result.backward()
        optimizer.step()
        running_loss += loss_result.item()
        steps += 1
        writer.add_image( tag: 'epoch_loss', running_loss, epoch)
        writer.add_scalar( tag: 'step_loss', loss_result, steps)
```

这些都是累加的，如果没有除以总数得到一个平均的他肯定是越来越大的

我总共加了多少个数据，就除以多少

- **实质：** 记录**每个 Batch 的损失**（`loss_result`）是可以的，但更常见、更有价值的做法是记录**短期的平均损失**（比如每 100 个 Batch 的平均损失）。
- **为什么不佳？** Batch 损失的波动性很大，直接记录 `loss_result` 会使你的 TensorBoard 图线**非常嘈杂**（锯齿状），难以看清真正的下降趋势。

不对，如果我是每搁一个固定的周期，把loss的数据清零，一样可以观察出loss的趋势。
如果我不清零，就要除以当前累加的总数才能观察出loss的变化趋势

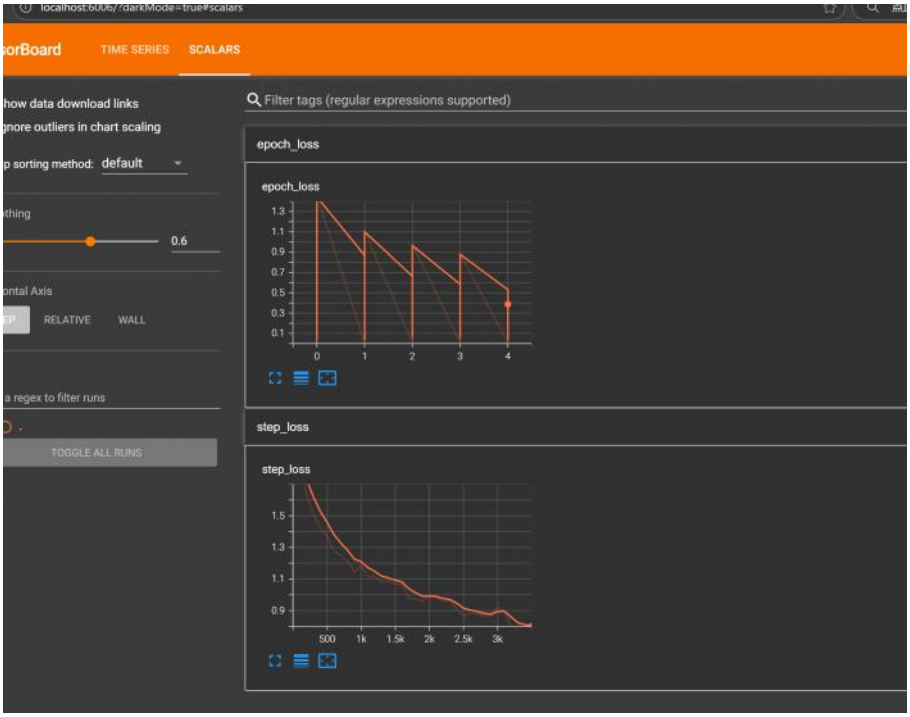

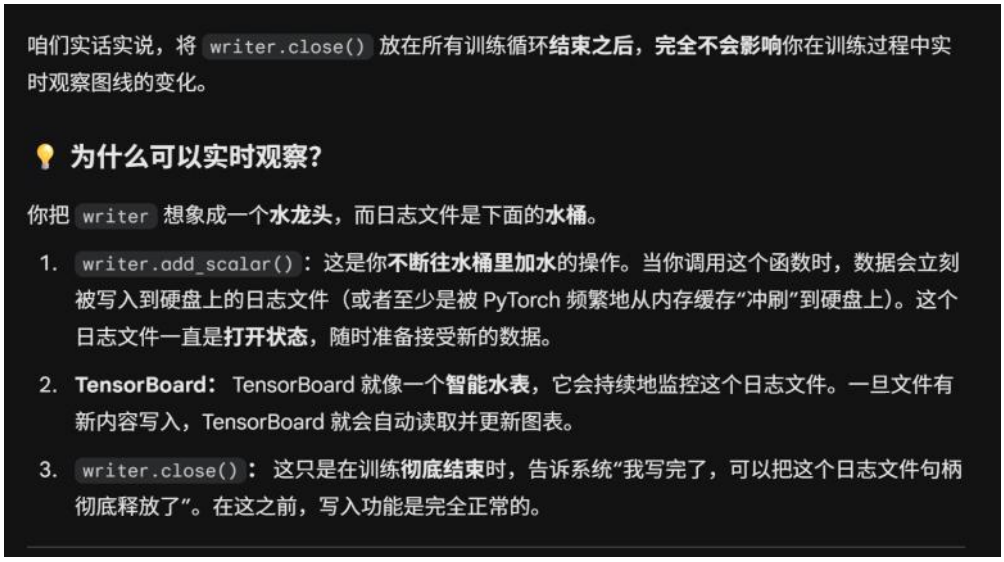

在训练过程中，会一直有新数据的产生，所以不用writer.close() ，数据也会更新

如果是那种一次性就读完的数据，没有新数据的推动，也没有close的指令，数据就不会被读取